



Школа информатики, физики и технологий

Машинное обучение и анализ данных

Детекция меланомы на дерматоскопических изображениях: от балансировки классов к интерпретируемым моделям компьютерного зрения

Никитина Дарья Дмитриевна






Санкт-Петербург, 2026





Проблема и мотивация

- Меланома - наиболее агрессивная форма рака кожи
- Стандартный метод диагностики – дерматоскопия: асимметрия, цвет, границы, дерматоскопические структуры
- У экспертов прогностическая валидность для меланомы составляет лишь 75-84%
- Скрининг в реальном масштабе - узкое место
- Запрос на автоматизированные системы поддержки диагностики
- Большинство моделей = «чёрный ящик»

Меланома



Доброкачественное





Обзор литературы и выбор архитектуры

Что известно из литературы:

- CNN (ResNet, DenseNet) — стандарт в дерматоскопии, >95% accuracy на ISIC/HAM10000 (Naseri & Safaei, 2025)
- ResNet-50 показывает наиболее сбалансированное качество среди CNN на ISIC 2020 при сравнении с VGG, DenseNet, ResNet-34/101 (Zhang et al., 2025)
- ViT и Swin конкурентоспособны с CNN в классификации кожных поражений (Yang et al., 2025)
- XAI статистически повышает доверие дерматологов к системе (Chanda et al., 2024)

Пробелы:

- Нет систематического сравнения CNN vs трансформеры при реальном дисбалансе 98/2
- Оценка XAI в дерматоскопии остаётся качественной, без количественного сравнения с разметкой врачей

Архитектура	ResNet	ViT-Small	Swin-Tiny
Кол-во параметров, млн	25,6	22,1	28



Цель и задачи исследования

Цель: Сравнить эффективность свёрточной и трансформерных архитектур для классификации меланомы в условиях реалистичного дисбаланса классов и количественно оценить интерпретируемость модели-победителя.


Задачи:

1. Подобрать оптимальную стратегию препроцессинга: разбиение данных, аугментацию и балансировку классов на архитектуре-бейзлайне ResNet-50
2. Подобрать гиперпараметры для каждой из трёх архитектур (ResNet-50, ViT-Small, Swin-Tiny) с помощью Optuna
3. Обучить 3 модели и сравнить их по AUC-PR, Recall и устойчивости генерализации на тестовой выборке
4. Выбрать финальную модель, дообучить её и применить Attention Rollout для визуализации областей внимания
5. Количественно оценить качество локализации через метрику Pointing Game на масках специалистов (ISIC 2016)



Данные

Распределение классов
ISIC 2020



ISIC2020 – датасет для обучения и оценки
моделей


33 126 дерматоскопических изображений,
бинарная метка: меланома / доброкачественное

+

ISIC2016 – датасет для оценки
интерпретируемости

1 279 изображений с попиксельными масками
поражений, размеченными дерматологами

🏆 Competitions



SIIM-ISIC Melanoma Classification

Identify melanoma in lesion images

Featured

3308 Teams

\$30,000 6 years ago



Метрики

Основные:


- AUC-PR – площадь под кривой точность-полнота, которая честно отражает работу с редким классом
- Recall – доля верно выявленных меланом среди всех реальных меланом
Приоритетная клиническая метрика:
пропущенная меланома = упущенное лечение
- F1-score — гармоническое среднее Precision и Recall, критерий выбора порога бинаризации предсказаний

Дополнительные:

- Precision – доля верных среди всех предсказанных меланом
 - Specificity – доля корректно классифицированных доброкачественных
- Balanced Accuracy – среднее Recall и Specificity, устойчива к дисбалансу, оценивает оба класса
- ROC-AUC – вычислен только для финальной модели, так как нечувствителен к дисбалансу, но является официальной метрикой соревнования ISIC2020
- Pointing Game - % пикселей с максимальной активацией, попавших в маску



Пайплайн препроцессинга



+59% к AUC-PR только за счёт грамотной подготовки данных



Методология обучения моделей

Optuna, 15 trials × 15 эпох, MedianPruner → топ-3 конфигурации × 30 эпох → лучшая × 50 эпох

Стратегия подбора гиперпараметров Optuna

Гиперпараметр	ResNet-50	ViT-Small / Swin-Tiny
Optimizator	Adam, AdamW, SGD	Adam, AdamW
Learning rate	1e-5 — 1e-2	1e-5 — 5e-4
Weight decay	1e-4 — 1e-2	1e-4 — 1e-1
Dropout	0 — 0.5	0 — 0.3
Label smoothing	0 — 0.2	
LR scheduler	StepLR, Cosine, OneCycle	




Результаты сравнения обученных архитектур

Метрика	ResNet-50	Swin-Tiny	ViT-Small
Val AUC-PR	0.2539	0.2944	0.2346
Test AUC-PR	0.1964	0.2519	0.2348
Разрыв val→test	−0.057↓	−0.043 ↓	+0.002 ↑
Test Recall	0.3151	0.3014	0.4384
Test F1	0.2754	0.3520	0.3459
Test Bal.Acc	0.6488	0.6470	0.7093

Победитель – ViT-Small: единственная модель без просадки при переходе на тест + наивысший Recall



ROC-AUC финальной модели



ROC-AUC финальной модели = 0,757


Сравнение с рынком:

- 1 место: ансамбль 18 разнородных CNN-моделей на основе ResNet, EfficientNet + объединённые датасеты + 5-fold CV + обработка различных входных разрешений – ROC-AUC = 0,949
- Ансамбль из EfficientNet-B3 + TTA + 5-fold CV – ROC-AUC = 0,83; AUC-PR = 0,56
- Одиночная модель ResNet50 + FFT – ROC-AUC = 0,7354, то есть ↑ на 0,0216 п.п. и ↓ compute



Интерпретируемость: Attention Rollout

Attention Rollout — ViT-Small/16



Pointing Game финальной модели = 21,1%



Выводы

Результаты:

- Препроцессинг: AUC-PR 0.12 $\rightarrow$ 0.19 (+59%) без смены архитектуры
- ViT-Small: лучшая генерализация (val $\rightarrow$ test AUC-PR: +0.002) и Recall = 0.44
- ROC-AUC = 0.757 - выше одиночного ResNet-50 без оптимизации (0.735)

Интерпретируемость:

- Pointing Game = 21.1% vs ~5–10% случайного baseline
- Классификация $\neq$ локализация: модель пока смотрит не туда, но классифицирует верно

Перспективы:

- Ансамблирование + TTA $\rightarrow$ потенциал +3-7% ROC-AUC
- Дообучение с масками на ISIC2016 $\rightarrow$ улучшение локализации внимания
- Использование объединённых датасетов



Использованные источники

- Chanda T. et al. Dermatologist-like explainable AI enhances trust and confidence in diagnosing melanoma //Nature Communications. – 2024. – Т. 15. – №. 1. – С. 524. — URL: <https://www.nature.com/articles/s41467-023-43095-4>
- Davila A., Colan J., Hasegawa Y. Comparison of fine-tuning strategies for transfer learning in medical image classification //Image and Vision Computing. – 2024. – Т. 146. – С. 105012.
- Ha Q., Liu B., Liu F. Identifying melanoma images using efficientnet ensemble: Winning solution to the siim-isic melanoma classification challenge //arXiv preprint arXiv:2010.05351. – 2020.
- Naseri H., Safaei A. A. Diagnosis and prognosis of melanoma from dermoscopy images using machine learning and deep learning: a systematic literature review //BMC cancer. – 2025. – Т. 25. – №. 1. – С. 75. — URL: <https://link.springer.com/article/10.1186/s12885-024-13423-y>
- Tahir M. et al. DSCC_Net: multi-classification deep learning models for diagnosing of skin cancer using dermoscopic images //Cancers. – 2023. – Т. 15. – №. 7. – С. 2179.
- Yang G., Luo S., Greer P. Boosting skin cancer classification: a multi-scale attention and ensemble approach with vision transformers //Sensors. – 2025. – Т. 25. – №. 8. – С. 2479. — URL: <https://www.mdpi.com/1424-8220/25/8/2479>
- Zhang P., Chaudhary D. Hybrid deep learning framework for enhanced melanoma detection //IEEE Transactions on Computational Biology and Bioinformatics. – 2025. — URL: <https://ieeexplore.ieee.org/abstract/document/11119348>



Школа информатики, физики и технологий

Машинное обучение и анализ данных

Детекция меланомы на дерматоскопических изображениях: от балансировки классов к интерпретируемым моделям компьютерного зрения


Никитина Дарья Дмитриевна

Репозиторий: https://github.com/nikidariya/Melanoma_Detection_With_Class_Imbalance

Санкт-Петербург, 2026




Эксперимент 1 - Val AUC-PR по эпохам (три варианта сплита)






Эксперимент 1 - Итоговые метрики по вариантам сплита






Эксперимент 2 - Val AUC-PR по эпохам (стратегии аугментации)






Эксперимент 2 - Val AUC-PR, F1, Recall по стратегиям аугментации






Эксперимент 3 - Val AUC-PR по эпохам (стратегии балансировки)






Эксперимент 3 - Val AUC-PR, F1, Recall по стратегиям балансировки







ResNet-50 - результаты триалов Optuna






ResNet-50 - Val AUC-PR по эпохам, топ-3 конфига (30 эпох)








ResNet-50 - Val AUC-PR по всем эпохам (Trial 4, SGD + OneCycleLR)






ResNet-50 - финальные метрики (глобальная эпоха 36, порог=0.50)






ViT - результаты триалов Optuna






ViT - Val AUC-PR по эпохам, топ-3 конфига (30 эпох)






ViT - финальные метрики топ-3 конфигов (val и test)






ViT - Val AUC-PR по всем эпохам (Trial 9, AdamW + CosineAnnealingLR)






ViT - финальные метрики (глобальная эпоха 37, порог=0.15)






Swin Transformer - результаты триалов Optuna






Swin Transformer - Val AUC-PR по эпохам, топ-3 конфига (30 эпох)






Swin Transformer - финальные метрики топ-3 конфигов (val и test)





Swin Transformer - Val AUC-PR по всем эпохам (Trial 10, AdamW + OneCycleLR)





Swin Transformer - финальные метрики (глобальная эпоха 30, порог=0.39)

