

Сопроводительная записка

Тема курсовой работы: «Детекция меланомы на дерматоскопических изображениях: от балансировки классов к интерпретируемым моделям компьютерного зрения»

Тематика программы: Computer Vision / Deep Learning.

Направление: Медицинская диагностика, интерпретируемый ИИ (ХАИ).

Автор: Никитина Дарья Дмитриевна

Актуальность

Меланома - наиболее агрессивная форма рака кожи. При ранней диагностике пятилетняя выживаемость достигает 98%, однако при распространении опухоли на отдалённые органы этот показатель падает ниже 15%¹. При этом глобальная заболеваемость меланомой продолжает расти: по прогнозам, к 2040 году число новых случаев превысит 510 000, а смертность возрастёт до 96 000 в год². Столь резкий контраст в выживаемости делает раннюю диагностику критически важной задачей.

В последние годы в медицинском компьютерном зрении наметился отчётливый сдвиг от свёрточных сетей к трансформерным архитектурам. Применительно к дерматоскопии ряд работ показал, что Vision Transformer и Swin Transformer способны превосходить классические CNN за счёт учёта глобальных зависимостей между областями изображения, особенно важного при анализе диффузных признаков меланомы таких как асимметрия и неравномерность цвета³. Вместе с тем сравнительный анализ этих архитектур в условиях выраженного дисбаланса классов, характерного для реальных скрининговых данных, остаётся недостаточно изученным. Многие существующие работы либо используют сбалансированные датасеты, либо ограничиваются одной архитектурой, не рассматривая взаимодействие стратегии балансировки и типа модели.

Также несмотря на высокую диагностическую точность современных моделей глубокого обучения, их клиническое внедрение остаётся ограниченным. Ключевым барьером является непрозрачность принимаемых решений: врач не

¹ Spanjaard R. et al. Perspective: melanoma diagnosis and monitoring: sunrise for melanoma therapy but early detection remains in the shade //arXiv preprint arXiv:1607.06720. – 2015. — URL: <https://arxiv.org/abs/1607.06720>

² Okobi O. E. et al. Trends in melanoma incidence, prevalence, stage at diagnosis, and survival: an analysis of the United States Cancer Statistics (USCS) database //Cureus. – 2024. – Т. 16. – №. 10. — URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC11529802/>

³ Aksoy S., Demircioglu P., Bogrekci I. Enhancing melanoma diagnosis with advanced deep learning models focusing on vision transformer, swin transformer, and convnext //Dermatopathology. – 2024. – Т. 11. – №. 3. – С. 239-252. — URL: <https://www.mdpi.com/2296-3529/11/3/26>

может принять диагноз "чёрного ящика" без понимания его оснований⁴. Исследование Chanda et al. показало, что добавление объяснимого AI к стандартной модели значительно повышает доверие дерматологов к системе и их диагностическую уверенность. Это подчёркивает, что интерпретируемость не академическая опция, а практическое условие применимости модели в клинике. Настоящая работа адресует оба барьера одновременно: исследует стратегии работы с реалистичным дисбалансом классов и количественно оценивает качество объяснений модели через сравнение тепловых карт с разметкой врачей.

Обзор предметной области

Дерматоскопия - неинвазивный метод визуализации кожных образований, основанный на использовании поляризованного света и оптического увеличения. Поляризация устраняет блики роговического слоя и открывает доступ к структурам эпидермиса и поверхностной дермы: пигментным сетям, глобулам, сосудистым паттернам. Для стандартизации интерпретации разработаны диагностические системы - ABCD-правило (Asymmetry, Border, Colour и Differential structures), семибалльный контрольный список и паттерн-анализ⁵.

Однако диагностическая точность метода принципиально зависит от квалификации специалиста. Даже при экспертном применении прогностическая валидность дерматоскопии для меланомы составляет лишь 75-84%⁶, а распознавание атипичных форм остаётся прерогативой специализированных центров с высоким потоком пациентов. Именно эта операторозависимость стала ключевой мотивацией для разработки автоматизированных систем диагностики.

В реальных клинических данных меланома составляет лишь около 2% от всех кожных образований, что порождает острую проблему дисбаланса классов. Для модели глубокого обучения это означает следующее: модель, предсказывающая «доброкачественное» для всех объектов, формально достигает 98% ассурасу, но при этом полностью бесполезна клинически, так как она не обнаруживает ни одного случая меланомы. Проблема в том, что при обучении на дисбалансированных данных модель видит примеры меланомы настолько редко, что не успевает выучить признаки, отличающие её от доброкачественных образований, и просто учится отвечать «доброкачественное» как на большинство обучающих примеров.

⁴ Chanda T. et al. Dermatologist-like explainable AI enhances trust and confidence in diagnosing melanoma //Nature Communications. – 2024. – Т. 15. – №. 1. – С. 524. — URL: <https://www.nature.com/articles/s41467-023-43095-4>

⁵ Alwakid G. et al. Diagnosing melanomas in dermoscopy images using deep learning //Diagnostics. – 2023. – Т. 13. – №. 10. – С. 1815. — URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC10217211/>

⁶ Ibid.

Для борьбы с дисбалансом в медицинских данных существует несколько групп методов⁷. Первая - ресэмплинг: либо искусственно добавляют копии/синтетические вариации редкого класса в обучающую выборку (oversampling), либо уменьшают количество примеров частого класса (undersampling). Вторая группа - взвешивание функции потерь: модели явно сообщают, что ошибка на меланоме "стоит дороже", и штраф за пропуск меланомы увеличивается пропорционально весовому коэффициенту. Частным случаем этого подхода является focal loss - функция потерь с динамической схемой взвешивания, которая снижает вес лёгких примеров и усиливает акцент на сложных, тем самым придавая большее значение образцам из редкого класса. Дополнительно применяется батч-балансировка: вместо случайной выборки примеров в каждый мини-батч принудительно включается равное количество объектов каждого класса, что гарантирует присутствие меланомы на каждом шаге обучения. Комбинация батч-балансировки и focal loss объединяет оба эффекта: уравнивает частоту появления классов в обучении и усиливает акцент на трудноклассифицируемых примерах.

Поскольку перебор всех стратегий балансировки на вычислительно тяжёлых трансформерных архитектурах нецелесообразен, в настоящей работе отбор лучшей стратегии проводится на ResNet как быстром и хорошо изученном бейслайне, после чего выбранная стратегия переносится на ViT и Swin Transformer.

CNN долгое время оставались доминирующей парадигмой в медицинском компьютерном зрении. Ключевым прорывом стала архитектура ResNet, предложенная He et al. в 2016 году: механизм остаточных связей решил проблему затухающих градиентов при обучении глубоких сетей и сделал ResNet стандартным бейслайном в задачах классификации изображений⁸. В дерматоскопии ряд CNN-архитектур, в частности DenseNet и глубокие свёрточные сети, продемонстрировал выдающиеся результаты, достигая более 95% точности на датасетах HAM10000 и ISIC при детекции меланомы⁹.

Однако CNN обладают принципиальным структурным ограничением: свёрточные операции по природе локальны: каждый нейрон обрабатывает лишь небольшую окрестность входного изображения, что ограничивает способность модели улавливать глобальные пространственные зависимости. Это критично

⁷ Araf I., Idri A., Chairi I. Cost-sensitive learning for imbalanced medical data: a review //Artificial Intelligence Review. – 2024. – Т. 57. – №. 4. — URL: https://www.researchgate.net/publication/378656435_Cost-sensitive_learning_for_imbalanced_medical_data_a_review

⁸ He K. et al. Deep residual learning for image recognition //Proceedings of the IEEE conference on computer vision and pattern recognition. – 2016. – С. 770-778. — URL: https://openaccess.thecvf.com/content_cvpr_2016/papers/He_Deep_Residual_Learning_CVPR_2016_paper.pdf

⁹ Naseri H., Safaei A. A. Diagnosis and prognosis of melanoma from dermoscopy images using machine learning and deep learning: a systematic literature review //BMC cancer. – 2025. – Т. 25. – №. 1. – С. 75. — URL: <https://link.springer.com/article/10.1186/s12885-024-13423-y>

для анализа меланомы, где диагностически значимые признаки: асимметрия, характер границы, неравномерность цвета - определяются на уровне всего изображения. Попытки расширить рецептивное поле за счёт углубления сети сопряжены с риском переобучения, особенно на медицинских датасетах ограниченного объёма¹⁰. Именно это фундаментальное ограничение CNN стало мотивацией для перехода к трансформерным архитектурам.

Vision Transformer (ViT), предложенный Dosovitskiy et al. в 2020 году, разбивает изображение на фиксированные патчи (например, 16 на 16 пикселей), представляет каждый патч как токен и обрабатывает всю последовательность механизмом self-attention¹¹. В отличие от свёртки, self-attention вычисляет взаимное влияние всех патчей одновременно - модель охватывает изображение целиком уже с первого слоя, не строя глобальное представление постепенно через стек локальных фильтров.

Классификация кожных поражений представляет собой крайне сложную задачу ввиду высокой внутриклассовой вариативности, значительного межклассового визуального сходства и наличия артефактов на снимках. Именно способность трансформеров улавливать глобальные зависимости делает их перспективными для анализа диффузных признаков меланомы - асимметрии и неравномерности цвета - распределённых по всей площади поражения.

Swin Transformer, предложенный Liu et al. в 2021 году, развивает идею ViT, вводя иерархическую структуру и механизм сдвигающихся окон (shifted windows)¹². Это позволяет строить признаки на нескольких масштабах при линейной вычислительной сложности относительно размера изображения, что является существенным преимуществом по сравнению с квадратичной сложностью классического ViT. Для медицинских изображений это особенно важно, поскольку диагностически значимые структуры существуют одновременно на локальном и глобальном уровнях. Трансформерные архитектуры демонстрируют конкурентоспособные результаты на дерматоскопических датасетах.

Для интерпретации решений моделей глубокого обучения на изображениях разработан ряд подходов. LIME и SHAP являются model-agnostic методами, то есть работают с любой архитектурой как с "чёрным ящиком". На изображениях оба метода разбивают снимок на суперпиксели (связные области пикселей со схожими значениями) и оценивают, как меняется предсказание

¹⁰ Xu Z., Guo X., Wang J. Enhancing skin lesion segmentation with a fusion of convolutional neural networks and transformer models //Heliyon. – 2024. – Т. 10. – №. 10. — URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC11130697/>

¹¹ Dosovitskiy A. et al. An image is worth 16x16 words: Transformers for image recognition at scale //arXiv preprint arXiv:2010.11929. – 2020. — URL: <https://arxiv.org/pdf/2010.11929/100>

¹² Yang G., Luo S., Greer P. Boosting skin cancer classification: a multi-scale attention and ensemble approach with vision transformers //Sensors. – 2025. – Т. 25. – №. 8. – С. 2479. — URL: <https://www.mdpi.com/1424-8220/25/8/2479>

модели при "отключении" различных областей¹³. LIME делает это через локальную аппроксимацию: случайно маскирует группы суперпикселей и строит простую линейную модель поверх полученных предсказаний. SHAP основан на теории игр и приписывает каждой области "справедливый вклад" в итоговое решение. Оба метода требуют сотен прогонов изображения через модель для получения одного объяснения, что делает их практически неприменимыми при работе с датасетами медицинских изображений высокого разрешения, а также они оба нестабильны. Например, SHAP демонстрирует деградацию показателей на 53% в офтальмологических приложениях при зашумлении входных данных¹⁴.

Для трансформерных архитектур (ViT, Swin) применяется Attention Rollout: анализируются матрицы внимания (attention maps), вычисляемые на каждом слое, то есть оценивается, на какие участки изображения модель "обращала внимание" на каждом этапе обработки. Поскольку внимание в глубоких слоях формируется с учётом внимания предыдущих слоёв, матрицы внимания последовательно перемножаются по всем слоям сети, что позволяет получить итоговую карту, отражающую суммарный вклад каждого патча изображения в финальное решение. Для CNN-архитектуры (ResNet), не обладающей встроенным механизмом self-attention, применяется Grad-CAM: берутся градиенты функции потерь относительно активаций последнего свёрточного слоя, то есть анализируется, какие нейроны "загорались" сильнее всего при классификации конкретного изображения. Метод интерпретации выбирается в зависимости от архитектуры модели-победителя. В обоих случаях на основе полученных карт строится тепловая визуализация, накладываемая на исходный снимок, подсвечивающая области изображения, наиболее значимые для решения модели.

Визуальная оценка тепловых карт субъективна и не позволяет сравнивать методы объяснимости количественно. Для объективной оценки используется сравнение с разметкой специалистов, попиксельными масками поражений. Pointing Game - простейшая и наиболее интерпретируемая метрика локализации: для каждого изображения определяется пиксель с максимальной активацией на тепловой карте и проверяется, попадает ли он в пределы маски поражения, размеченной врачом. Результат бинарный, итоговая метрика – это доля верно локализованных изображений. Среди доступных метрик оценки локализации Pointing Game рассматривается как наиболее практичная для клинических

¹³ Ennab M., Mcheick H. Advancing AI interpretability in medical imaging: a comparative analysis of pixel-level interpretability and Grad-CAM models //Machine Learning and Knowledge Extraction. – 2025. – Т. 7. – №. 1. – С. 12. — URL: <https://www.mdpi.com/2504-4990/7/1/12>

¹⁴ Singh Y. et al. Beyond post hoc explanations: a comprehensive framework for accountable AI in medical imaging through transparency, interpretability, and explainability //Bioengineering. – 2025. – Т. 12. – №. 8. – С. 879. — URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC12383817/>

приложений интерпретируемости¹⁵. Это объясняется тем, что альтернативные overlap-метрики по типу IoU требуют бинаризации тепловой карты по пороговому значению, выбор которого произволен и существенно влияет на результат, делая сравнение ненадёжным.

Анализ литературы позволяет выделить два ключевых пробела. Во-первых, существующие сравнительные работы, как правило, исследуют отдельные архитектуры изолированно или используют данные, изначально близкие к сбалансированным, то есть без систематического сравнения того, как разные стратегии борьбы с дисбалансом взаимодействуют с разными архитектурами в условиях реального скрининга, где доля меланомы не превышает 2%. Во-вторых, оценка качества ХАИ-объяснений в дерматоскопии преимущественно остаётся качественной, а не количественной: тепловые карты визуально сопоставляются с ожиданиями без количественного измерения того, насколько точно модель локализует поражение относительно разметки специалистов.

Постановка задачи

Рассматривается задача бинарной классификации дерматоскопических изображений. На вход модели подаётся цветное изображение кожного образования в формате RGB, полученное методом дерматоскопии. На выходе модель должна производить скалярную вероятность принадлежности изображения к классу меланомы: значение, близкое к 1, соответствует положительному диагнозу, близкое к 0 - доброкачественному образованию.

Обучение проводится на датасете ISIC2020, содержащем 33 126 дерматоскопических изображений с бинарными метками, из которых менее 2% составляют случаи меланомы. Оценка качества объяснений модели проводится на датасете ISIC2016, содержащем попиксельные маски поражений, размеченные специалистами-дерматологами.

Поскольку стандартная метрика accuracy непригодна при таком уровне дисбаланса классов, а AUC-ROC нечувствителен к ошибкам на редком классе при высокой цене пропуска, основной метрикой качества классификации выбрана AUC-PR. PR-кривая не использует истинно отрицательные примеры и потому честно отражает способность модели находить редкий класс: случайная модель при 2% меланомы даёт $AUC-PR = 0,02$, тогда как хорошая модель стремится к 1. Фокус на положительном классе является осознанным выбором, продиктованным медицинским контекстом: цена пропуска меланомы несравнимо выше цены ложного срабатывания. В качестве вспомогательных

¹⁵ Ozer C. et al. Consistent explainable image quality assessment for medical imaging //Health Information Science and Systems. – 2026. – Т. 14. – №. 1. – С. 31. — URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC12819959/>

пороговых метрик, вычисляемых при оптимальном пороге, подобранном по валидационной выборке, используются: Recall (Sensitivity) - доля верно выявленных меланом, Precision - доля верных среди всех предсказанных меланом, F1-score - гармоническое среднее Precision и Recall, Specificity - доля здоровых пациентов, корректно классифицированных как доброкачественные, Balanced Accuracy - среднее арифметическое Recall и Specificity, устойчивое к дисбалансу классов. Совместное рассмотрение этих метрик позволяет контролировать как полноту выявления меланом, так и уровень ложных срабатываний. Качество локализации объяснений оценивается метрикой Pointing Game.

Обучение проводится на бесплатных GPU-ресурсах платформ Kaggle и Google Colab (NVIDIA T4 или A100 с ограничением по времени сессии). Это накладывает ограничения на размер батча, количество эпох обучения и число экспериментов, которые можно провести параллельно. В частности, полный перебор всех стратегий балансировки на трансформерных архитектурах вычислительно нецелесообразен, поэтому отбор стратегии выполняется на ResNet.

Отсутствие дообучения на клинических данных: все модели обучаются исключительно на публичных датасетах ISIC без доступа к внутренним клиническим данным конкретных медицинских учреждений. Это означает, что результаты отражают потенциал методов в условиях открытых данных и не могут напрямую экстраполироваться на конкретную клиническую систему без дообучения.

Отсутствие участия оператора в процессе инференса: система работает в полностью автоматическом режиме, то есть входное изображение подаётся напрямую, без предварительной разметки области интереса врачом. Это приближает условия к реальному скринингу, но одновременно усложняет задачу по сравнению с работами, где дерматолог предварительно выделяет область поражения.

Выбор метода

В качестве бейслайна выбрана архитектура ResNet. Выбор обусловлен тремя факторами: ResNet является хорошо изученным стандартом в задачах классификации медицинских изображений, демонстрирует стабильные и воспроизводимые результаты на дерматоскопических датасетах, и при этом вычислительно значительно дешевле трансформерных архитектур, что делает его оптимальным инструментом для отбора стратегии балансировки классов. Результаты ResNet с лучшей найденной стратегией балансировки служат точкой отсчёта для оценки трансформерных моделей.

Основными исследуемыми архитектурами выбраны ViT и Swin Transformer. Как показано в обзоре предметной области, механизм self-attention позволяет этим моделям улавливать глобальные пространственные зависимости с первого слоя в отличие от CNN, которые строят глобальное представление постепенно через стек локальных свёрток. Это свойство принципиально важно для меланомы, диагностические признаки которой (асимметрия и неравномерность цвета) распределены по всему изображению, а не локализованы в одной области. Swin Transformer дополнительно обеспечивает иерархическое представление признаков на нескольких масштабах, что позволяет одновременно анализировать как мелкие структурные детали, так и глобальную форму поражения.

EfficientNet, также широко применяемый в дерматоскопии, не включён в сравнение: являясь CNN-архитектурой, он разделяет принципиальное ограничение ResNet в части глобальных зависимостей, и его включение не позволило бы ответить на ключевой исследовательский вопрос о преимуществах трансформерного подхода.

Стратегия борьбы с дисбалансом классов определена экспериментально на архитектуре ResNet-50 путём последовательного сравнения пяти подходов: случайного оверсэмплинга меланом, взвешенной функции потерь (Weighted BCE), сбалансированного батч-сэмплера (Balanced batch), Focal Loss с подбором гиперпараметров α и γ посредством байесовской оптимизации (Optuna), а также их комбинации - Balanced batch совместно с Focal Loss. Использование ResNet-50 на этапе отбора стратегии обосновано вычислительной эффективностью: перебор подходов на ViT и Swin Transformer потребовал бы значительно большего времени обучения без гарантии переносимости результатов на другие архитектуры. Найденная лучшая стратегия затем применяется ко всем архитектурам, что обеспечивает сопоставимость условий сравнения. Перед отбором стратегии балансировки зафиксированы оптимальное разбиение данных и наилучшая стратегия аугментации, выбранные на тех же данных без применения каких-либо методов балансировки, что обеспечивает контролируемость экспериментов.

Выбор метода интерпретации определяется архитектурой модели-победителя: для трансформерных архитектур используется Attention Rollout, для ResNet, в случае его победы, используется Grad-CAM. Как показано в обзоре, LIME и SHAP требуют сотен прогонов модели для объяснения одного изображения, нестабильны и зависят от произвольных гиперпараметров метода. Attention Rollout и Grad-CAM, в отличие от них, вычисляются за один проход модели и не вносят внешних гиперпараметров: объяснение является прямым следствием внутреннего устройства самой архитектуры (механизма внимания для трансформеров или свёрточных активаций для CNN). Это делает оба метода

практичным выбором для количественной оценки локализации на большом датасете, при этом каждый из них применяется к архитектуре, для которой он естественен методологически. Для трансформерных архитектур применяет Attention Rollout, так как в статьях чаще всего именно он используется, что удобно для сравнения.

Качество объяснений оценивается с помощью метрики Pointing Game на датасете ISIC2016, содержащем попиксельные маски поражений, размеченные специалистами. Это позволяет ответить на вопрос не только "какая архитектура точнее классифицирует меланому", но и "какая архитектура смотрит туда, куда смотрит врач".

Бейслайном для финального сравнения служит ResNet с лучшей стратегией балансировки классов, найденной на этапе отбора. Такой выбор бейслайна обеспечивает честное сравнение: улучшение со стороны ViT и Swin Transformer объясняется именно архитектурными преимуществами трансформеров, а не тем, что бейслайн не умел бороться с дисбалансом.

Исследование

Для обучения и оценки моделей используется датасет ISIC 2020 из соревнования SIIM-ISIC Melanoma Classification на Kaggle¹⁶. Это набор дерматоскопических изображений кожных образований с бинарной меткой: меланома или доброкачественное образование.

В работе используется версия датасета jpeg-melanoma-256x256¹⁷, где изображения уже приведены к единому размеру 256x256 пикселей и обрезаны относительно исходных снимков соревнования. Это решает проблему разнородности исходных файлов (разные разрешения и соотношения сторон в оригинальном датасете) и снижает вычислительную нагрузку при обучении на ограниченных GPU-ресурсах Kaggle и Google Colab. Дополнительной очистки данных (удаление дубликатов, артефактов, испорченных файлов) я не проводила: используется датасет в исходном виде, без модификации состава выборки.

Всего датасет содержит 33 126 изображений, из которых менее 2% относятся к классу меланомы, что отражает реальное распределение классов при скрининге кожных образований и формирует основную методологическую сложность всей работы.

¹⁶ SIIM-ISIC Melanoma Classification. — URL: <https://www.kaggle.com/competitions/siim-isic-melanoma-classification>

¹⁷ JPEG Melanoma 256x256. — URL: <https://www.kaggle.com/datasets/cdeotte/jpeg-melanoma-256x256>

Поскольку перебор всех вариантов препроцессинга и балансировки на трёх архитектурах одновременно вычислительно нецелесообразен, отбор был проведён на ResNet-50 как на быстром бейзлайне, после чего лучшая найденная конфигурация была перенесена на ViT и Swin Transformer.

Сначала было подобрано разбиение данных на train/val/test: были сравнены три варианта с разной долей val/test. Нужно было найти баланс: маленькая тестовая выборка даёт слишком мало примеров меланомы для надёжной оценки, а слишком большая уменьшает обучающую выборку и мешает модели выучить признаки редкого класса.

Далее, на зафиксированном сплите, была подобрана стратегия аугментации: были сравнены базовая геометрическая аугментация, расширенная геометрическая, цветовая, комбинированная и агрессивная. Геометрические трансформации (обрезка, флипы) дают разнообразие ракурсов без искажения цвета, а цвет для меланомы является диагностически значимым признаком, поэтому слишком агрессивные или цветовые искажения оказались хуже.

Наконец, на зафиксированном сплите и аугментации была подобрана стратегия борьбы с дисбалансом классов: были сравнены оверсэмплинг, weighted BCE, balanced batch, focal loss и комбинация balanced batch с focal loss. Лучшей по совокупности качества и стабильности обучения оказалась стратегия balanced batch.

Найденная конфигурация препроцессинга и балансировки была зафиксирована и перенесена на все три исследуемые архитектуры. Далее для каждой из них отдельно проводился подбор гиперпараметров: схема подбора была единой, но поисковое пространство отличалось с учётом специфики конкретного типа сети.

На первом этапе для каждой архитектуры было запущено 15 trials по 15 эпох с использованием Optuna и MedianPruner, отсекающего заведомо слабые конфигурации до завершения полного цикла обучения. Качество конфигурации на этом этапе оценивалось по val AUC-PR, усреднённом за последние 3 эпохи. История всех trials сохранялась в SQLite, что позволяет в любой момент восстановить и проанализировать ход подбора без повторного запуска экспериментов.

Поисковое пространство для ResNet-50 включало выбор между тремя оптимизаторами (Adam, AdamW, SGD), тремя планировщиками learning rate (StepLR, CosineAnnealingLR, OneCycleLR), а также learning rate, weight decay, dropout и label smoothing. Такой широкий выбор оптимизаторов и планировщиков оправдан тем, что CNN-архитектуры в целом устойчивее к выбору этих гиперпараметров, чем трансформеры, и SGD для ResNet остаётся реалистичным вариантом.

Для ViT-Small и Swin-Tiny (такой размер моделей выбран так, чтобы количество параметров было сопоставимо с ResNet-50: 22.1М и 28М против 25.6М соответственно, что обеспечивает честное сравнение архитектур без искажения результата за счёт банально большей ёмкости модели) поисковое пространство было сужено с учётом известных особенностей трансформерных архитектур. Из числа оптимизаторов был исключён SGD, поскольку он плохо работает с трансформерами. Диапазон learning rate был смещён в сторону меньших значений ($1e-5$ до $5e-4$ против $1e-5$ до $1e-2$ для ResNet), так как трансформеры менее стабильны при высоком learning rate. Диапазон weight decay, напротив, был расширен в сторону больших значений ($1e-4$ до $1e-1$), поскольку трансформеры более склонны к переобучению, чем CNN, и для них регуляризация через weight decay играет более важную роль. Диапазон dropout был сужен (0 до 0.3 против 0 до 0.5 для ResNet), так как обе трансформерные архитектуры уже содержат встроенный dropout, и избыточная дополнительная регуляризация могла бы мешать обучению. Диапазон label smoothing остался одинаковым для всех трёх архитектур (0 до 0.2).

По результатам 15 trials для каждой архитектуры были отобраны три конфигурации с наилучшим val AUC-PR (тем же показателем, что использовался во время самого подбора, без повторного запуска), которые затем обучались дольше, на 30 эпох, для более надёжной оценки. Из этих трёх конфигураций по тому же критерию val AUC-PR была выбрана одна лучшая, которая дообучалась ещё на 20 эпох (итого 50 эпох с учётом предыдущего этапа), с early stopping по терпению 7 эпох при отсутствии роста val AUC-PR.

По итогам полного цикла для всех трёх архитектур наилучший результат показал ViT-Small, поэтому именно его финальные веса были использованы для визуализации Attention Rollout.

Для обеспечения воспроизводимости результатов были зафиксированы все источники случайности в эксперименте. Во всех трёх ноутбуках перед началом обучения устанавливается единый seed (42) для генераторов случайных чисел Python, NumPy и PyTorch, включая отдельную установку seed для CUDA. Дополнительно были отключены недетерминированные оптимизации cuDNN (`torch.backends.cudnn.benchmark = False`) и включён детерминированный режим (`torch.backends.cudnn.deterministic = True`), что устраняет основной источник недетерминированности при обучении на GPU.

Разбиение данных на train, val и test зафиксировано не программно (то есть не пересчитывается заново при каждом запуске по тому же seed), а явно сохранено в виде отдельных CSV-файлов, что исключает любую зависимость результата от различий в реализации разбиения между запусками или окружениями.

Все материалы работы (ноутбук с подбором конфигурации препроцессинга и балансировки, по одному ноутбуку на каждую из трёх архитектур с подбором гиперпараметров через Optuna, ноутбук с Attention Rollout, а также зафиксированные CSV-файлы со сплитами, requirements.txt) доступны в публичном репозитории¹⁸, а в файле readme.md располагается ссылка на веса лучшей модели на Kaggle.

Метрики и оценки

В условиях выраженного дисбаланса классов (менее 2% меланом) выбор метрик качества является принципиальным методологическим решением. Стандартная accuracy в данной задаче непригодна, медицинский контекст дополнительно усиливает асимметрию требований: ложноотрицательный результат - пропущенная меланома - несравнимо опаснее ложноположительного, поскольку своевременно не выявленная опухоль существенно снижает выживаемость пациента. Это делает полноту выявления положительного класса приоритетом при оценке моделей.

В качестве основной метрики на всех этапах экспериментов использовалась AUC-PR - площадь под кривой точность-полнота. В отличие от ROC-AUC, PR-кривая не использует истинно-отрицательные примеры и потому честно отражает способность модели находить редкий класс: случайная модель при 2% меланомы даёт AUC-PR около 0,02, тогда как совершенная модель стремится к 1. ROC-AUC дополнительно вычислен только для финальной модели-победителя - для сопоставления с результатами соревнования Kaggle SIIM-ISIC 2020, в котором эта метрика являлась официальной.

Пороговые метрики вычислялись при оптимальном пороге бинаризации, подобранном по максимуму F1 на валидационной выборке и зафиксированном для применения на тестовой:

- Recall (Sensitivity) – доля верно выявленных меланом среди всех реальных меланом. Приоритетная клиническая метрика: отражает, насколько полно модель обнаруживает опасные случаи.
- Precision - доля верных среди всех предсказанных меланом. Контролирует уровень ложных тревог, чрезмерное число которых перегружает клинический процесс повторными обследованиями.
- F1-score - гармоническое среднее Precision и Recall. Служит критерием подбора порога бинаризации, балансируя полноту и точность.

- Specificity - доля корректно классифицированных доброкачественных образований. Отражает, насколько редко модель ошибочно направляет здоровых пациентов на дообследование.
- Balanced Accuracy - среднее арифметическое Recall и Specificity. Устойчива к дисбалансу классов и позволяет оценить поведение модели на обоих классах одновременно.

Итоговое значение эксперимента на всех этапах подбора - среднее val AUC-PR за последние три эпохи, что снижает влияние взрывов метрик в рамках одной эпохи.

Отбор конфигурации препроцессинга проводился последовательно: сначала подбирался сплит, затем при зафиксированном сплите - стратегия аугментации, затем при зафиксированных сплите и аугментации - стратегия балансировки. Лучшими оказались сплит 75/12.5/12.5, базовая геометрическая аугментация без цветовых искажений (цвет является диагностически значимым признаком меланомы) и сбалансированный батч-сэмплер. Val AUC-PR последовательно вырос с 0,1221 до 0,1785 и до 0,1941 (см. рис. 1). Найденная конфигурация зафиксирована и перенесена на все три архитектуры.




Рисунок 1 – Рост Val AUC-PR в ходе экспериментов в препроцессинге

По результатам финального обучения трёх архитектур были получены следующие значения val AUC-PR: ResNet-50 - 0.2539, Swin-Tiny - 0.2944, ViT-Small - 0.2346. Формально наилучший val AUC-PR показал Swin-Tiny, однако на тестовой выборке его результат заметно просел (0.2519), что свидетельствует о недостаточном обобщении. Аналогичная картина наблюдается у ResNet-50: разрыв между val и test AUC-PR составил 0.06 пункта. ViT-Small, напротив,

продемонстрировал практически идентичные значения на валидации и тесте (0.2346 и 0.2348), что указывает на устойчивую генерализацию. Дополнительным аргументом в пользу ViT-Small служит существенно более высокий Recall на тестовой выборке (0.4384 против 0.3151 у ResNet-50 и 0.3014 у Swin-Tiny) - в задаче онкологического скрининга именно полнота выявления положительного класса является приоритетной клинической характеристикой. По совокупности этих критериев в качестве финальной модели был выбран ViT-Small, финальные веса которого использовались для Attention Rollout. Динамика val AUC-PR по эпохам для ViT-Small представлена на рисунке 2.




Рисунок 2 – ViT: Val AUC-PR на протяжении всех эпох


Для количественной оценки интерпретируемости финальной модели применялся Attention Rollout на датасете ISIC 2016 (379 изображений с попиксельными масками поражений, размеченными специалистами). Датасет использовался как полностью отложенная выборка - модель не видела его ни на одном этапе обучения.

Метрика Pointing Game зафиксировала точность локализации 21.1% (80 попаданий из 379). Результат заметно превышает уровень случайного угадывания - при типичной доле площади поражения от общей площади снимка случайная точка попадает в маску в 5-10% случаев, однако до надёжной клинической локализации далеко.

Качественный анализ шести примеров (см. рис. 3) раскрывает природу этого расхождения. На изображениях меланом модель нередко фокусирует внимание за пределами поражения, однако при этом уверенно предсказывает положительный класс с высокой вероятностью. Это указывает на то, что модель опирается на глобальные текстурные и цветовые признаки снимка, а не

локализует конкретное поражение - типичное поведение трансформера, обученного на задаче классификации без явного сигнала локализации. На доброкачественных примерах картина обратная: внимание сосредоточено в области поражения, вероятность меланомы низкая, классификация верная.

Attention Rollout — ViT-Small/16






Рисунок 3 – Реализация Attention Rollout

Расхождение между качеством классификации и локализацией внимания на меланомах является известной проблемой трансформерных моделей в медицинских задачах: модель решает задачу классификации, но не задачу детекции, поэтому Attention Rollout не гарантирует клинически осмысленного указания на поражение.

Выводы

По итогам сравнения трёх архитектур ViT-Small продемонстрировал наилучшее сочетание обобщающей способности и клинически приоритетного показателя Recall: val и test AUC-PR практически совпали (0.2346 и 0.2348), а Recall на тестовой выборке составил 0.4384 - существенно выше, чем у ResNet-50 (0.3151) и Swin-Tiny (0.3014). Оба конкурирующих решения показали заметный разрыв между val и test AUC-PR (0.06 у ResNet-50 и 0.04 у Swin-Tiny), что свидетельствует о менее устойчивой генерализации.

Также финальная модель достигла ROC-AUC = 0.757. Этот показатель не отражает проблему дисбаланса классов и склонен давать завышенные оценки при редком положительном классе, но использовался как основная метрика на соревновании ISIC, так что был намеренно посчитан на финальной модели для сравнения результатов.

Победившее в соревновании решение представляло собой ансамбль 18 разнородных CNN-моделей на основе EfficientNet B3-B7, SE-ResNeXt101 и ResNest101, обученных на объединённых данных ISIC 2019 и 2020 с применением пятикратной кросс-валидации и нескольких входных разрешений от 384 до 1024 пикселей, и достигло ROC-AUC = 0.949¹⁹. Это решение принципиально отличается по масштабу: 18 моделей в финальном ансамбле, вдвое больший объём обучающих данных и несопоставимо большие

¹⁹ Ha Q., Liu B., Liu F. Identifying melanoma images using efficientnet ensemble: Winning solution to the siim-isic melanoma classification challenge //arXiv preprint arXiv:2010.05351. – 2020.

вычислительные затраты в отличие от авторской одиночной модели, обученной в рамках бесплатных GPU-квот Kaggle за одну сессию.

Более корректным ориентиром служат одиночные модели без ансамблирования. Davila et al. (2024)²⁰ в рамках сравнительного исследования стратегий дообучения на медицинских изображениях протестировали ResNet-50 (25.6М параметров, предобучение на ImageNet) на ISIC 2020 с наивным полным дообучением всех слоёв без балансировки классов и подбора гиперпараметров - и получили ROC-AUC 73.54%. ViT-Small/16 в настоящей работе при сопоставимом числе параметров (22.1М), но с байесовской оптимизацией гиперпараметров и сбалансированным батч-сэмплером превосходит этот результат на 2.2 процентных пункта.

Компактные свёрточные модели на основе EfficientNet-B3 с применением test-time augmentation (ТТА, аугментация входных изображений в момент инференса с усреднением предсказаний) и пятикратной кросс-валидацией достигали ROC-AUC 0.83 и PR-AUC 0.56. Разрыв с полученным результатом объясняется именно этими техниками: ТТА и кросс-валидация стабильно обеспечивают прирост ROC-AUC на 3-7 процентных пунктов и в настоящей работе не применялись ввиду ограничений вычислительных ресурсов²¹.

Отдельно следует отметить, что подавляющее большинство рассмотренных работ ограничивается метриками классификации, не затрагивая вопрос интерпретируемости принимаемых решений. Работы по дерматоскопии фиксируют характерную для трансформерных моделей тенденцию к рассеянным картам внимания за пределами области поражения - даже при высокой точности классификации, однако количественной оценки этого явления, как правило, не проводится. В настоящей работе применение Attention Rollout и метрики Pointing Game на масках специалистов датасета ISIC 2016 позволило не только зафиксировать это ограничение численно (21.1%), но и содержательно интерпретировать его: модель опирается на глобальные текстурные признаки снимка, а не локализует конкретное поражение - что является прямым следствием обучения исключительно на метке класса без сигнала локализации.

Таким образом, настоящая работа демонстрирует, что трансформерная архитектура в условиях реалистичного дисбаланса классов способна превзойти свёрточный бейслайн по устойчивости обобщения и клинически приоритетному показателю Recall при сопоставимом числе параметров и существенно меньших вычислительных затратах. Вместе с тем высокое качество классификации само по себе не гарантирует клинической интерпретируемости модели - разрыв между

²⁰ Davila A., Colan J., Hasegawa Y. Comparison of fine-tuning strategies for transfer learning in medical image classification //Image and Vision Computing. – 2024. – Т. 146. – С. 105012.

²¹ Tahir M. et al. DSCC_Net: multi-classification deep learning models for diagnosing of skin cancer using dermoscopic images //Cancers. – 2023. – Т. 15. – №. 7. – С. 2179.

тем, что модель предсказывает, и тем, на что она при этом смотрит, остаётся ключевым барьером для внедрения подобных систем в реальную диагностическую практику.