

Сопроводительная записка

Тема курсовой работы: «Детекция меланомы на дерматоскопических изображениях: от балансировки классов к интерпретируемым моделям компьютерного зрения»

Тематика программы: Computer Vision / Deep Learning.

Направление: Медицинская диагностика, интерпретируемый ИИ (ХАИ).

Автор: Никитина Дарья Дмитриевна

Актуальность

Меланома - наиболее агрессивная форма рака кожи. При ранней диагностике пятилетняя выживаемость достигает 98%, однако при распространении опухоли на отдалённые органы этот показатель падает ниже 15%¹. При этом глобальная заболеваемость меланомой продолжает расти: по прогнозам, к 2040 году число новых случаев превысит 510 000, а смертность возрастёт до 96 000 в год². Столь резкий контраст в выживаемости делает раннюю диагностику критически важной задачей.

В последние годы в медицинском компьютерном зрении наметился отчётливый сдвиг от свёрточных сетей к трансформерным архитектурам. Применительно к дерматоскопии ряд работ показал, что Vision Transformer и Swin Transformer способны превосходить классические CNN за счёт учёта глобальных зависимостей между областями изображения, особенно важного при анализе диффузных признаков меланомы таких как асимметрия и неравномерность цвета³. Вместе с тем сравнительный анализ этих архитектур в условиях выраженного дисбаланса классов, характерного для реальных скрининговых данных, остаётся недостаточно изученным. Многие существующие работы либо используют сбалансированные датасеты, либо ограничиваются одной архитектурой, не рассматривая взаимодействие стратегии балансировки и типа модели.

Также несмотря на высокую диагностическую точность современных моделей глубокого обучения, их клиническое внедрение остаётся ограниченным. Ключевым барьером является непрозрачность принимаемых решений: врач не

¹ Spanjaard R. et al. Perspective: melanoma diagnosis and monitoring: sunrise for melanoma therapy but early detection remains in the shade //arXiv preprint arXiv:1607.06720. – 2015. — URL: <https://arxiv.org/abs/1607.06720>

² Okobi O. E. et al. Trends in melanoma incidence, prevalence, stage at diagnosis, and survival: an analysis of the United States Cancer Statistics (USCS) database //Cureus. – 2024. – Т. 16. – №. 10. — URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC11529802/>

³ Aksoy S., Demircioglu P., Bogrekci I. Enhancing melanoma diagnosis with advanced deep learning models focusing on vision transformer, swin transformer, and convnext //Dermatopathology. – 2024. – Т. 11. – №. 3. – С. 239-252. — URL: <https://www.mdpi.com/2296-3529/11/3/26>

может принять диагноз "чёрного ящика" без понимания его оснований⁴. Исследование Chanda et al. показало, что добавление объяснимого AI к стандартной модели значительно повышает доверие дерматологов к системе и их диагностическую уверенность. Это подчёркивает, что интерпретируемость не академическая опция, а практическое условие применимости модели в клинике. Настоящая работа адресует оба барьера одновременно: исследует стратегии работы с реалистичным дисбалансом классов и количественно оценивает качество объяснений модели через сравнение тепловых карт с разметкой врачей.

Обзор предметной области

Дерматоскопия - неинвазивный метод визуализации кожных образований, основанный на использовании поляризованного света и оптического увеличения. Поляризация устраняет блики роговического слоя и открывает доступ к структурам эпидермиса и поверхностной дермы: пигментным сетям, глобулам, сосудистым паттернам. Для стандартизации интерпретации разработаны диагностические системы - ABCD-правило (Asymmetry, Border, Colour и Differential structures), семибалльный контрольный список и паттерн-анализ⁵.

Однако диагностическая точность метода принципиально зависит от квалификации специалиста. Даже при экспертном применении прогностическая валидность дерматоскопии для меланомы составляет лишь 75-84%⁶, а распознавание атипичных форм остаётся прерогативой специализированных центров с высоким потоком пациентов. Именно эта операторозависимость стала ключевой мотивацией для разработки автоматизированных систем диагностики.

В реальных клинических данных меланома составляет лишь около 2% от всех кожных образований, что порождает острую проблему дисбаланса классов. Для модели глубокого обучения это означает следующее: модель, предсказывающая «доброкачественное» для всех объектов, формально достигает 98% ассюрасу, но при этом полностью бесполезна клинически, так как она не обнаруживает ни одного случая меланомы. Проблема в том, что при обучении на дисбалансированных данных модель видит примеры меланомы настолько редко, что не успевает выучить признаки, отличающие её от доброкачественных образований, и просто учится отвечать «доброкачественное» как на большинство обучающих примеров.

⁴ Chanda T. et al. Dermatologist-like explainable AI enhances trust and confidence in diagnosing melanoma //Nature Communications. – 2024. – Т. 15. – №. 1. – С. 524. — URL: <https://www.nature.com/articles/s41467-023-43095-4>

⁵ Alwakid G. et al. Diagnosing melanomas in dermoscopy images using deep learning //Diagnostics. – 2023. – Т. 13. – №. 10. – С. 1815. — URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC10217211/>

⁶ Ibid.

Для борьбы с дисбалансом в медицинских данных существует несколько групп методов⁷. Первая - ресэмплинг: либо искусственно добавляют копии/синтетические вариации редкого класса в обучающую выборку (oversampling), либо уменьшают количество примеров частого класса (undersampling). Вторая группа - взвешивание функции потерь: модели явно сообщают, что ошибка на меланоме "стоит дороже", и штраф за пропуск меланомы увеличивается пропорционально весовому коэффициенту. Частным случаем этого подхода является focal loss - функция потерь с динамической схемой взвешивания, которая снижает вес лёгких примеров и усиливает акцент на сложных, тем самым придавая большее значение образцам из редкого класса. Дополнительно применяется батч-балансировка: вместо случайной выборки примеров в каждый мини-батч принудительно включается равное количество объектов каждого класса, что гарантирует присутствие меланомы на каждом шаге обучения. Комбинация батч-балансировки и focal loss объединяет оба эффекта: уравнивает частоту появления классов в обучении и усиливает акцент на трудноклассифицируемых примерах.

Поскольку перебор всех стратегий балансировки на вычислительно тяжёлых трансформерных архитектурах нецелесообразен, в настоящей работе отбор лучшей стратегии проводится на ResNet как быстром и хорошо изученном бейслайне, после чего выбранная стратегия переносится на ViT и Swin Transformer.

CNN долгое время оставались доминирующей парадигмой в медицинском компьютерном зрении. Ключевым прорывом стала архитектура ResNet, предложенная He et al. в 2016 году: механизм остаточных связей решил проблему затухающих градиентов при обучении глубоких сетей и сделал ResNet стандартным бейслайном в задачах классификации изображений⁸. В дерматоскопии ряд CNN-архитектур, в частности DenseNet и глубокие свёрточные сети, продемонстрировал выдающиеся результаты, достигая более 95% точности на датасетах HAM10000 и ISIC при детекции меланомы⁹.

Однако CNN обладают принципиальным структурным ограничением: свёрточные операции по природе локальны: каждый нейрон обрабатывает лишь небольшую окрестность входного изображения, что ограничивает способность модели улавливать глобальные пространственные зависимости. Это критично

⁷ Araf I., Idri A., Chairi I. Cost-sensitive learning for imbalanced medical data: a review //Artificial Intelligence Review. – 2024. – Т. 57. – №. 4. — URL: https://www.researchgate.net/publication/378656435_Cost-sensitive_learning_for_imbalanced_medical_data_a_review

⁸ He K. et al. Deep residual learning for image recognition //Proceedings of the IEEE conference on computer vision and pattern recognition. – 2016. – С. 770-778. — URL: https://openaccess.thecvf.com/content_cvpr_2016/papers/He_Deep_Residual_Learning_CVPR_2016_paper.pdf

⁹ Naseri H., Safaei A. A. Diagnosis and prognosis of melanoma from dermoscopy images using machine learning and deep learning: a systematic literature review //BMC cancer. – 2025. – Т. 25. – №. 1. – С. 75. — URL: <https://link.springer.com/article/10.1186/s12885-024-13423-y>

для анализа меланомы, где диагностически значимые признаки: асимметрия, характер границы, неравномерность цвета - определяются на уровне всего изображения. Попытки расширить рецептивное поле за счёт углубления сети сопряжены с риском переобучения, особенно на медицинских датасетах ограниченного объёма¹⁰. Именно это фундаментальное ограничение CNN стало мотивацией для перехода к трансформерным архитектурам.

Vision Transformer (ViT), предложенный Dosovitskiy et al. в 2020 году, разбивает изображение на фиксированные патчи (например, 16 на 16 пикселей), представляет каждый патч как токен и обрабатывает всю последовательность механизмом self-attention¹¹. В отличие от свёртки, self-attention вычисляет взаимное влияние всех патчей одновременно - модель охватывает изображение целиком уже с первого слоя, не строя глобальное представление постепенно через стек локальных фильтров.

Классификация кожных поражений представляет собой крайне сложную задачу ввиду высокой внутриклассовой вариативности, значительного межклассового визуального сходства и наличия артефактов на снимках. Именно способность трансформеров улавливать глобальные зависимости делает их перспективными для анализа диффузных признаков меланомы - асимметрии и неравномерности цвета - распределённых по всей площади поражения.

Swin Transformer, предложенный Liu et al. в 2021 году, развивает идею ViT, вводя иерархическую структуру и механизм сдвигающихся окон (shifted windows)¹². Это позволяет строить признаки на нескольких масштабах при линейной вычислительной сложности относительно размера изображения, что является существенным преимуществом по сравнению с квадратичной сложностью классического ViT. Для медицинских изображений это особенно важно, поскольку диагностически значимые структуры существуют одновременно на локальном и глобальном уровнях. Трансформерные архитектуры демонстрируют конкурентоспособные результаты на дерматоскопических датасетах.

Для интерпретации решений моделей глубокого обучения на изображениях разработан ряд подходов. LIME и SHAP являются model-agnostic методами, то есть работают с любой архитектурой как с "чёрным ящиком". На изображениях оба метода разбивают снимок на суперпиксели (связные области пикселей со схожими значениями) и оценивают, как меняется предсказание

¹⁰ Xu Z., Guo X., Wang J. Enhancing skin lesion segmentation with a fusion of convolutional neural networks and transformer models //Heliyon. – 2024. – Т. 10. – №. 10. — URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC11130697/>

¹¹ Dosovitskiy A. et al. An image is worth 16x16 words: Transformers for image recognition at scale //arXiv preprint arXiv:2010.11929. – 2020. — URL: <https://arxiv.org/pdf/2010.11929/100>

¹² Yang G., Luo S., Greer P. Boosting skin cancer classification: a multi-scale attention and ensemble approach with vision transformers //Sensors. – 2025. – Т. 25. – №. 8. – С. 2479. — URL: <https://www.mdpi.com/1424-8220/25/8/2479>

модели при "отключении" различных областей¹³. LIME делает это через локальную аппроксимацию: случайно маскирует группы суперпикселей и строит простую линейную модель поверх полученных предсказаний. SHAP основан на теории игр и приписывает каждой области "справедливый вклад" в итоговое решение. Оба метода требуют сотен прогонов изображения через модель для получения одного объяснения, что делает их практически неприменимыми при работе с датасетами медицинских изображений высокого разрешения, а также они оба нестабильны. Например, SHAP демонстрирует деградацию показателей на 53% в офтальмологических приложениях при зашумлении входных данных¹⁴.

Grad-CAM использует принципиально иной подход: он смотрит внутрь самой модели, а не снаружи¹⁵. Для CNN берутся градиенты функции потерь относительно активаций последнего свёрточного слоя, то есть анализируется, какие нейроны «загорались» сильнее всего при классификации конкретного изображения. На основе этих градиентов строится тепловая карта, накладываемая на исходный снимок. Grad-CAM подсвечивает области изображения, важные для решения модели, генерируя тепловые карты. Для трансформерных архитектур разработана адаптация ViT-GradCAM, использующая матрицы внимания совместно с градиентами вместо активаций свёрточных слоёв.

Визуальная оценка тепловых карт субъективна и не позволяет сравнивать методы объяснимости количественно. Для объективной оценки используется сравнение с разметкой специалистов, попиксельными масками поражений. Pointing Game - простейшая и наиболее интерпретируемая метрика локализации: для каждого изображения определяется пиксель с максимальной активацией на тепловой карте и проверяется, попадает ли он в пределы маски поражения, размеченной врачом. Результат бинарный, итоговая метрика – это доля верно локализованных изображений. Среди доступных метрик оценки локализации Pointing Game рассматривается как наиболее практичная для клинических приложений интерпретируемости¹⁶. Это объясняется тем, что альтернативные overlap-метрики по типу IoU требуют бинаризации тепловой карты по пороговому значению, выбор которого произволен и существенно влияет на результат, делая сравнение ненадёжным.

¹³ Ennab M., Mcheick H. Advancing AI interpretability in medical imaging: a comparative analysis of pixel-level interpretability and Grad-CAM models //Machine Learning and Knowledge Extraction. – 2025. – Т. 7. – №. 1. – С. 12. — URL: <https://www.mdpi.com/2504-4990/7/1/12>

¹⁴ Singh Y. et al. Beyond post hoc explanations: a comprehensive framework for accountable AI in medical imaging through transparency, interpretability, and explainability //Bioengineering. – 2025. – Т. 12. – №. 8. – С. 879. — URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC12383817/>

¹⁵ Chaddad A. et al. Generalizable and explainable deep learning for medical image computing: An overview //Current Opinion in Biomedical Engineering. – 2025. – Т. 33. – С. 100567. — URL: <https://arxiv.org/pdf/2503.08420>

¹⁶ Ozer C. et al. Consistent explainable image quality assessment for medical imaging //Health Information Science and Systems. – 2026. – Т. 14. – №. 1. – С. 31. — URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC12819959/>

Анализ литературы позволяет выделить два ключевых пробела. Во-первых, существующие сравнительные работы, как правило, исследуют отдельные архитектуры изолированно или используют данные, изначально близкие к сбалансированным, то есть без систематического сравнения того, как разные стратегии борьбы с дисбалансом взаимодействуют с разными архитектурами в условиях реального скрининга, где доля меланомы не превышает 2%. Во-вторых, оценка качества ХАИ-объяснений в дерматоскопии преимущественно остаётся качественной, а не количественной: тепловые карты визуально сопоставляются с ожиданиями без количественного измерения того, насколько точно модель локализует поражение относительно разметки специалистов.

Постановка задачи

Рассматривается задача бинарной классификации дерматоскопических изображений. На вход модели подаётся цветное изображение кожного образования в формате RGB, полученное методом дерматоскопии. На выходе модель должна производить скалярную вероятность принадлежности изображения к классу меланомы: значение, близкое к 1, соответствует положительному диагнозу, близкое к 0 - доброкачественному образованию.

Обучение проводится на датасете ISIC2020, содержащем 33 126 дерматоскопических изображений с бинарными метками, из которых менее 2% составляют случаи меланомы. Оценка качества объяснений модели проводится на датасете ISIC2016, содержащем попиксельные маски поражений, размеченные специалистами-дерматологами.

Поскольку стандартная метрика accuracy непригодна при таком уровне дисбаланса классов, а AUC-ROC нечувствителен к ошибкам на редком классе при высокой цене пропуска, основной метрикой качества классификации выбрана AUC-PR. PR-кривая не использует истинно отрицательные примеры и потому честно отражает способность модели находить редкий класс: случайная модель при 2% меланомы даёт $AUC-PR = 0,02$, тогда как хорошая модель стремится к 1. Фокус на положительном классе является осознанным выбором, продиктованным медицинским контекстом: цена пропуска меланомы несравнимо выше цены ложного срабатывания. В качестве вспомогательных пороговых метрик, вычисляемых при оптимальном пороге, подобранном по валидационной выборке, используются: Recall (Sensitivity) - доля верно выявленных меланом, Precision - доля верных среди всех предсказанных меланом, F1-score - гармоническое среднее Precision и Recall, Specificity - доля здоровых пациентов, корректно классифицированных как доброкачественные, Balanced Accuracy - среднее арифметическое Recall и Specificity, устойчивое к

дисбалансу классов. Совместное рассмотрение этих метрик позволяет контролировать как полноту выявления меланом, так и уровень ложных срабатываний. Качество локализации объяснений оценивается метрикой Pointing Game.

Обучение проводится на бесплатных GPU-ресурсах платформ Kaggle и Google Colab (NVIDIA T4 или A100 с ограничением по времени сессии). Это накладывает ограничения на размер батча, количество эпох обучения и число экспериментов, которые можно провести параллельно. В частности, полный перебор всех стратегий балансировки на трансформерных архитектурах вычислительно нецелесообразен, поэтому отбор стратегии выполняется на ResNet.

Отсутствие дообучения на клинических данных: все модели обучаются исключительно на публичных датасетах ISIC без доступа к внутренним клиническим данным конкретных медицинских учреждений. Это означает, что результаты отражают потенциал методов в условиях открытых данных и не могут напрямую экстраполироваться на конкретную клиническую систему без дообучения.

Отсутствие участия оператора в процессе инференса: система работает в полностью автоматическом режиме, то есть входное изображение подаётся напрямую, без предварительной разметки области интереса врачом. Это приближает условия к реальному скринингу, но одновременно усложняет задачу по сравнению с работами, где дерматолог предварительно выделяет область поражения.

Выбор метода

В качестве бейслайна выбрана архитектура ResNet. Выбор обусловлен тремя факторами: ResNet является хорошо изученным стандартом в задачах классификации медицинских изображений, демонстрирует стабильные и воспроизводимые результаты на дерматоскопических датасетах, и при этом вычислительно значительно дешевле трансформерных архитектур, что делает его оптимальным инструментом для отбора стратегии балансировки классов. Результаты ResNet с лучшей найденной стратегией балансировки служат точкой отсчёта для оценки трансформерных моделей.

Основными исследуемыми архитектурами выбраны ViT и Swin Transformer. Как показано в обзоре предметной области, механизм self-attention позволяет этим моделям улавливать глобальные пространственные зависимости с первого слоя в отличие от CNN, которые строят глобальное представление постепенно через стек локальных свёрток. Это свойство принципиально важно

для меланомы, диагностические признаки которой (асимметрия и неравномерность цвета) распределены по всему изображению, а не локализованы в одной области. Swin Transformer дополнительно обеспечивает иерархическое представление признаков на нескольких масштабах, что позволяет одновременно анализировать как мелкие структурные детали, так и глобальную форму поражения.

EfficientNet, также широко применяемый в дерматоскопии, не включён в сравнение: являясь CNN-архитектурой, он разделяет принципиальное ограничение ResNet в части глобальных зависимостей, и его включение не позволило бы ответить на ключевой исследовательский вопрос о преимуществах трансформерного подхода.

Стратегия борьбы с дисбалансом классов определена экспериментально на архитектуре ResNet-50 путём последовательного сравнения пяти подходов: случайного оверсэмплинга меланом, взвешенной функции потерь (Weighted BCE), сбалансированного батч-сэмплера (Balanced batch), Focal Loss с подбором гиперпараметров α и γ посредством байесовской оптимизации (Optuna), а также их комбинации - Balanced batch совместно с Focal Loss. Использование ResNet-50 на этапе отбора стратегии обосновано вычислительной эффективностью: перебор подходов на ViT и Swin Transformer потребовал бы значительно большего времени обучения без гарантии переносимости результатов на другие архитектуры. Найденная лучшая стратегия затем применяется ко всем архитектурам, что обеспечивает сопоставимость условий сравнения. Перед отбором стратегии балансировки зафиксированы оптимальное разбиение данных и наилучшая стратегия аугментации, выбранные на тех же данных без применения каких-либо методов балансировки, что обеспечивает контролируемость экспериментов.

Для интерпретации решений модели выбран Grad-CAM и его адаптация для трансформеров ViT-GradCAM. Как показано в обзоре, LIME и SHAP требуют сотен прогонов модели для объяснения одного изображения, нестабильны и зависят от произвольных гиперпараметров метода. Grad-CAM, напротив, вычисляется за один обратный проход и не вносит внешних гиперпараметров, так что объяснение является прямым следствием работы самой модели. Это делает его наиболее практичным выбором для количественной оценки локализации на большом датасете.

Качество объяснений оценивается с помощью метрики Pointing Game на датасете ISIC2016, содержащем попиксельные маски поражений, размеченные специалистами. Это позволяет ответить на вопрос не только "какая архитектура точнее классифицирует меланому", но и "какая архитектура смотрит туда, куда смотрит врач".

Бейслайном для финального сравнения служит ResNet с лучшей стратегией балансировки классов, найденной на этапе отбора. Такой выбор бейслайна обеспечивает честное сравнение: улучшение со стороны ViT и Swin Transformer объясняется именно архитектурными преимуществами трансформеров, а не тем, что бейслайн не умел бороться с дисбалансом.